

PROPOSTA DI R&D

AI Locale per l'Automazione di Task Time Consuming

LLM On-Premise · RAG · Agenti Specializzati

Mauro Di Rollo | 2026

CONFIDENZIALE — USO INTERNO

Il Contesto

Dove spendiamo il tempo che non abbiamo

01

La sfida quotidiana del team

Il team di ingegneri software opera in un contesto di altissima criticità dove ogni riga di codice deve rispettare standard rigorosi come **MISRA C/C++**, verificati tramite analisi statica con **Coverity**. Questo genera un volume significativo di lavoro manuale e ripetitivo che sottrae tempo all'innovazione.

Attività ad alto costo e bassa variabilità

1

Analisi manuale deviazioni MISRA da Coverity

Task ripetitivo, alto volume, regole ben definite — candidato ideale per l'automazione.

2

Ricerca su documentazione interna e standard tecnici

Informazioni disperse su più fonti. Il team perde tempo a rintracciare contesto.

3

Deviation justification ad ogni ciclo di build


Stesso sforzo documentativo ripetuto ad ogni release senza possibilità di riuso.

La Soluzione

Intelligenza Artificiale locale, sicura e specializzata

02

Proponiamo una piattaforma AI completamente **on-premise**: nessun dato esce dall'azienda, nessuna dipendenza da servizi cloud. Il sistema si fonda su tre elementi:



Il flusso operativo (alto livello)



I documenti vengono processati una volta e persistiti nel Vector DB. Da quel momento ogni agente accede alla conoscenza in millisecondi.

Architettura Tecnica

RAG, Vector DB e Agenti — come funziona davvero

03

Cos'è il RAG (Retrieval-Augmented Generation)

Un LLM standard risponde basandosi solo su ciò che ha imparato durante il training. Il **RAG** aggiunge un passo di *ricerca* prima della generazione: il modello interroga una knowledge base contestuale e costruisce la risposta usando informazioni fresche e specifiche del dominio. Questo elimina le allucinazioni su contenuti aziendali e rende il sistema aggiornabile senza re-training.

1

Query in ingresso

L'utente (o l'agente) pone una domanda o fornisce un input da analizzare.

2

Embedding della query

La query viene convertita in un vettore numerico tramite un modello di embedding.

3

Ricerca nel Vector DB

Si cercano i chunk di documenti più simili alla query (cosine similarity).

4

Context augmentation

I chunk rilevanti vengono iniettati nel prompt del LLM come contesto.

5

Generazione risposta

Il LLM genera una risposta fondata sui documenti recuperati.

Cos'è un Agente AI

Un **agente** è un LLM dotato di *strumenti* (tool) che può chiamare autonomamente per completare task complessi in più passi. A differenza di una singola chiamata LLM, l'agente pianifica, esegue, osserva il risultato e itera fino al completamento del task.

LLM Base

- Risponde in un solo turno
- Nessuna memoria tra chiamate
- Non può usare strumenti esterni
- Prone ad allucinazioni su dati aziendali

Agente AI con RAG

- Pianifica e itera su più passi
- Accede alla knowledge base aziendale
- Chiama tool: parser Coverity, diff codice, linter
- Risponde solo su fatti verificabili dalla KB

Architettura Proposta

Sources → Ingestion → RAG Engine → Agenti + Output

04



LLM Open-Source Consigliati

Modelli verificati con licenza permissiva per uso commerciale/interno

Per un contesto aerospace con requisiti di privacy e sicurezza, la scelta del modello deve considerare tre fattori: **licenza** (pieno uso commerciale/interno), **performance** sul task di code reasoning e **footprint HW** compatibile con l'infrastruttura on-premise. Licenze verificate a maggio 2025.

Modelli raccomandati

Modello	Licenza	Param.	VRAM min.	Punto di forza	Anno
Mistral 3 (3B / 8B / 14B)	Apache 2.0	3B – 14B	4 – 16 GB	Famiglia piu aggiornata Mistral. Vision + testo, 40+ lingue, ragionamento avanzato.	2025
Mixtral 8x7B Mixtral 8x22B	Apache 2.0	47B / 141B (att.: 13/39B)	24 / 80 GB	Mixture-of-Experts: alta capacita a basso costo di inferenza. Ottimo su codice e math.	~2024
Microsoft Phi-4 (14B)	MIT	14B	16 GB	Ragionamento tecnico eccellente per la taglia. Supera modelli piu grandi su STEM e coding.	2025
DeepSeek-R1 (distillati 7B-70B)	MIT	7B – 70B	8 – 80 GB	Chain-of-thought avanzato. Performance paragonabile a o1 su math, code e reasoning.	2025

Phi-4-mini (3.8B)	MIT	3.8B	4 GB	Deploy su HW limitato o edge. Function calling integrato, ottimo per agenti leggeri.	2025
Qwen3 235B-A22B (MoE)	Apache 2.0	235B (att.: 22B)	~80 GB (4-bit)	Top open-source su coding e reasoning. Modalita Thinking per ragionamento step-by-step.	2026
Qwen 3.6 (35B-A3B MoE)	Apache 2.0	35B (att.: 3B)	~8 GB	Focalizzato su workflow agentici. Efficientissimo: solo 3B parametri attivi per token.	Apr 2026
DeepSeek V4-Flash (MoE)	MIT	284B (att.: 13B)	~90 GB (1 GPU H100)	Miglior rapporto qualita/costo 2026. 1M token context. Coding benchmark: 91.6% LiveCodeBench.	Apr 2026
DeepSeek V4-Pro (MoE, flagship)	MIT	1.6T (att.: 49B)	Multi-GP U (4x H200+)	Frontier open-source. 80.6% SWE-bench, pari a Claude Opus 4.6. Solo per infra enterprise.	Apr 2026

Raccomandazione per il pilota: Phi-4 (14B, MIT) o Qwen 3.6 35B-A3B (Apache 2.0) sono il punto di partenza ottimale — il secondo attiva solo 3B parametri per token e gira su hardware singolo. Per task più complessi in fase 2: Qwen3 235B o DeepSeek V4-Flash.

Nota: licenze verificate a maggio 2026 dalle fonti ufficiali (Hugging Face, GitHub, documentazione ufficiale dei modelli). DeepSeek V4-Pro richiede infrastruttura multi-GPU enterprise (4x H200+) e non è adatto al pilota iniziale. Verificare con il team legale prima del deploy in produzione.

ROI & Roadmap

Dati di settore, ritorni attesi e piano di implementazione

07

Le stime di impatto sono basate su studi pubblicati e dati industriali verificati. I valori si riferiscono a contesti di analisi statica e compliance su codice C/C++ safety-critical, comparabili al nostro dominio applicativo.

10-20 min

per alarm di ispezione manuale su falsi positivi

[1] arXiv 2601.18844

94-98%

falsi positivi eliminati con LLM + analisi statica

[1] arXiv 2601.18844

21-28%

riduzione tempo per violazione MISRA con AI

[2] Embedded.com 2022

3.6 h/sett.

risparmiate per dev con AI tools (135k devs)

[3] DX Research 2025

Impatto atteso sul processo MISRA/Coverity

Metrica	Baseline	Con agente AI	Fonte
Tempo ispezione per alarm	10-20 min/alarm (manuale)	Classificazione automatica — riduzione significativa	[1]
False positive non actionable	50-70% degli alert Coverity	94-98% eliminati automaticamente	[1]
Tempo su violazioni MISRA	Baseline attuale del team	Calo del 21-28% dimostrato su codebase reali	[2]
Risparmio settimanale per dev	Media industria senza AI	~3.6 ore/settimana (dati su 135.000 sviluppatori)	[3]
Costo licenza LLM	API cloud: variabile e ricorrente	Zero — modelli MIT/Apache 2.0 self-hosted	Slide 05

Piano di implementazione

Fase 1 1-2 mesi	Setup HW, installazione LLM, configurazione Vector DB, ingestion knowledge base MISRA e policy interne. Misurazione baseline (ore/alarm, volume violazioni).
Fase 2 2-4 mesi	Sviluppo agente MISRA/Coverity, integrazione pipeline CI/CD, testing e validazione. Primo confronto con baseline misurata in Fase 1.
Fase 3 4-6 mesi	Produzione, monitoraggio continuo, feedback loop. Sviluppo agenti aggiuntivi su task prioritari (DO-178C, test generation).

Riferimenti

- [1] Reducing False Positives in Static Bug Detection with LLMs — Tencent / arXiv, gennaio 2026
arxiv.org/abs/2601.18844
- [2] Using AI to Reduce the Burden of MISRA — Embedded.com, dicembre 2022
embedded.com/using-ai-to-reduce-the-burden-of-misra
- [3] AI Coding Assistant Statistics (dataset 135.000 sviluppatori) — DX Research / Panto, 2025
getpanto.ai/blog/ai-coding-assistant-statistics
- [4] AI Code Review Automation: Complete Guide — Digital Applied, dicembre 2025
digitalapplied.com/blog/ai-code-review-automation-guide-2025

Nota: i valori esatti dipenderanno dalla baseline del team e dalla qualità della knowledge base. Si raccomanda di misurare la baseline prima del pilota per quantificare il delta reale.

Requisiti Hardware & Scalabilità


Dimensionamento per 15-40 utenti paralleli, latenza <5s, mix batch + interattivo

08

Con un target di **15-40 richieste parallele** e latenza **<5 secondi** in modalita mista (batch CI/CD + uso interattivo), la configurazione minima necessaria cambia significativamente rispetto a un deployment singolo-utente. Le stime di concorrenza sono basate su benchmark vLLM/SGLang pubblicati su H100. Prezzi GPU: mercato maggio 2026.

FASE PILOTA	PRODUZIONE MINIMA	PRODUZIONE CONSIGLIATA
Mesi 1-4 validazione tecnica	Mesi 4+ mix batch + interattivo	Mesi 4+ target reale 15-40 utenti
GPU 1x H100 PCIe 80 GB ~27.000 USD — inferenza stabile, ECC memory	GPU 2x H100 PCIe 80 GB ~54.000 USD — data parallelism	GPU 4x H100 PCIe 80 GB ~108.000 USD — 2 batch + 2 interattivi
RAM 128 GB DDR5 Vector DB + runtime multi-agente	RAM 256 GB DDR5 Multi-agente + pipeline CI/CD	RAM 512 GB DDR5 Separazione batch/interattivo
STORAGE 4 TB NVMe Modelli, embeddings, log	STORAGE 8 TB NVMe Modelli, log, history, backup	STORAGE 16 TB NVMe RAID Alta disponibilit�
RETE 10 GbE Accesso team	RETE 10 GbE Accesso concorrente	RETE 25 GbE Throughput multi-agente
8-12 richieste parallele <5s	25-35 richieste parallele <5s	35-50 richieste parallele <5s
MODELLI Phi-4 14B, Mistral 3 8B, Qwen 3.6 35B-A3B (3B attivi)	MODELLI Qwen 3.6 35B-A3B, Phi-4 14B, Mistral 3 8B	MODELLI Qwen3 235B-A22B, DeepSeek V4-Flash, Mixtral 8x22B, Phi-4 14B
Sufficiente per validare il workflow MISRA con un subset del team.	Con MoE (3B attivi/token): regge il target con margine. [5]	2 GPU batch CI/CD + 2 GPU interattive. Scalabile a 8x GPU.

Capacita di concorrenza per configurazione — utenti paralleli con latenza <5s



Confronto configurazioni — costi e throughput (dati H100, vLLM 2026)

Configurazio ne	GPU (costo)	Utenti <5s	Throughput	CapEx totale est.	Fonte
Pilota	1x H100 PCIe ~27.000 USD	8-12	~12.500 tok/s (Phi-4 14B, vLLM)	~32.000 USD	[1][3]
Prod. Minima	2x H100 PCIe ~54.000 USD	25-35	~22.000 tok/s (Qwen3.6 MoE, FP8)	~72.000 USD	[2][3]
Prod. Consigliata	4x H100 PCIe ~108.000 USD	35-50	~4x indep. 2 batch + 2 interattivi	~130.000 USD	[1][4]
Espansione	8x H100 PCIe ~216.000 USD	80-100+	Tensor parallel + data parallel	~250.000 USD	[4]

Raccomandazione: avviare il pilota con **1x H100** (~32.000 USD totali) per validare il workflow MISRA. Passare a **4x H100** (~130.000 USD) per la produzione, con separazione dedicata tra GPU batch e GPU interattive. Il breakeven vs cloud si raggiunge a ~115 giorni di utilizzo continuativo [4]. La configurazione 4x è espandibile a 8x senza modificare l'architettura software.

Riferimenti

- [1] vLLM Benchmarks: Throughput, Latency & Production Stack Guide — morphllm.com, aprile 2026
morphllm.com/vllm-benchmarks
- [2] Benchmarking LLM Performance on Different GPUs in 2026 — dasroot.net, aprile 2026
dasroot.net/posts/2026/04/benchmarking-llm-performance-gpus-2026
- [3] NVIDIA H100 GPU Price Guide: Buy vs Rent in 2026 — electronics.alibaba.com, maggio 2026
electronics.alibaba.com/question/nvidia-h100-price-guide-buy-vs-rent-in-2026
- [4] LLM Inference On-Premise vs Cloud: 2026 Cost and Break-Even Analysis — spheron.network
spheron.network/blog/llm-inference-on-premise-vs-cloud
- [5] On-Premises Hardware Sizing Guide for LLM Inference (marzo 2026) — iternal.ai
iternal.ai/hardware-sizing-guide